

Colecciones no secuenciales

Ricardo Pérez López

IES Doñana, curso 2025/2026

Generado el 2026/01/29 a las 20:45:00

Índice

1. Conjuntos (set y frozenset)	1
1.1. Definición	1
1.2. Conjuntos por comprensión	4
1.3. Operaciones	5
1.4. Operaciones sobre conjuntos mutables	6
1.5. Recorrido de conjuntos	7
2. Diccionarios (dict)	7
2.1. Definición	7
2.2. Diccionarios por comprensión	11
2.3. Operaciones	12
2.4. Recorrido de diccionarios	13
3. Documentos XML	14
3.1. Definición	14
3.2. Acceso	16
3.3. Modificación	21

1. Conjuntos (set y frozenset)

1.1. Definición

Un conjunto es una colección **no ordenada** de elementos *hashables*.

Se usan frecuentemente para comprobar si un elemento pertenece a un grupo, para eliminar duplicados en una secuencia y para realizar operaciones matemáticas como la *unión*, la *intersección* y la *diferencia simétrica*.

Como cualquier otra colección, los conjuntos permiten el uso de:

- `x in c`
- `len(c)`

- `for x in c`

Como son colecciones no ordenadas, los conjuntos **no almacenan la posición** de los elementos o el **orden** en el que se insertaron.

Por tanto, tampoco admiten la indexación, las rodajas ni cualquier otro comportamiento propio de las secuencias.

Cuando decimos que **un conjunto no está ordenado**, queremos decir que los elementos que contiene no se encuentran situados en una posición concreta.

Es lo contrario de lo que ocurre con las secuencias, donde cada elemento se encuentra en una posición indicada por su **índice** y podemos acceder a él usando la indexación.

Además, en un conjunto **no puede haber elementos repetidos** (un elemento concreto sólo puede estar *una vez* dentro de un conjunto, es decir, o está una vez o no está).

En resumen:

En un conjunto:

- Un elemento concreto, o está una vez, o no está.
- Si está, no podemos saber en qué posición (no tiene sentido preguntárselo).

Existen dos tipos predefinidos de conjuntos: `set` y `frozenset`.

El tipo `set[t]` representa el tipo de los conjuntos de tipo `set` cuyas elementos son todos de tipo `t`.

Por ejemplo, el tipo `set[str]` representa el tipo de los conjuntos mutables cuyos elementos son todos cadenas.

El tipo `set` es **mutable**, es decir, que su contenido puede cambiar usando métodos como `add` y `remove`.

Como es mutable, **no es hashable** y, por tanto, no puede usarse como clave de un diccionario o como elemento de otro conjunto.

El tipo `frozenset` es **inmutable** y **hashable**. Por tanto, su contenido no se puede cambiar una vez creado y puede usarse como clave de un diccionario o como elemento de otro conjunto.

El tipo `frozenset[t]` representa el tipo de los conjuntos de tipo `frozenset` cuyas elementos son todos de tipo `t`.

Por ejemplo, el tipo `frozenset[str]` representa el tipo de los conjuntos inmutables cuyos elementos son todos cadenas.

Los dos tipos de conjuntos se crean con las funciones `set([<iterable>])` y `frozenset([<iterable>])`:

- Si se llaman *sin argumentos*, devuelven un conjunto **vacío**:
 - `set()` devuelve un conjunto vacío de tipo `set`.
 - `frozenset()` devuelve un conjunto vacío de tipo `frozenset`.

```
>>> set()
set()
>>> frozenset()
frozenset()
```

Como se ve, esas son, precisamente, las **expresiones canónicas** de un conjunto vacío de tipo `set` y `frozenset`.

- Si se les pasa un *iterable* (como por ejemplo, una lista), devuelve un conjunto formado por los elementos del iterable:

```
>>> set([4, 3, 2, 2, 4])
{2, 3, 4}
>>> frozenset([4, 3, 2, 2, 4])
frozenset({2, 3, 4})
```

Además, existe una *sintaxis especial* para escribir **literales de conjuntos no vacíos de tipo `set`**, que consiste en encerrar sus elementos entre llaves y separados por comas: `{'pepe', 'juan'}`.

```
>>> x = {'pepe', 'juan'} # un literal de tipo set, como set(['pepe', 'juan'])
>>> x
{'pepe', 'juan'}
>>> type(x)
<class 'set'>
```

Esa es, precisamente, la **expresión canónica** de un conjunto no vacío y, por tanto, la **forma normal** de cualquier expresión que evalúa a un conjunto vacío. Por eso es la expresión que se usa cuando se visualiza desde el intérprete o se imprime con `print`.

Por tanto, para crear conjuntos congelados usando `frozenset` podemos usar esa sintaxis en lugar de usar listas como hicimos antes:

```
>>> frozenset({4, 3, 2, 2, 4})
frozenset({2, 3, 4})
```

También podría usarse con la función `set`, pero entonces estaríamos creando un nuevo conjunto igual que el anterior, aunque no idéntico (es decir, sería una *copia* del original):

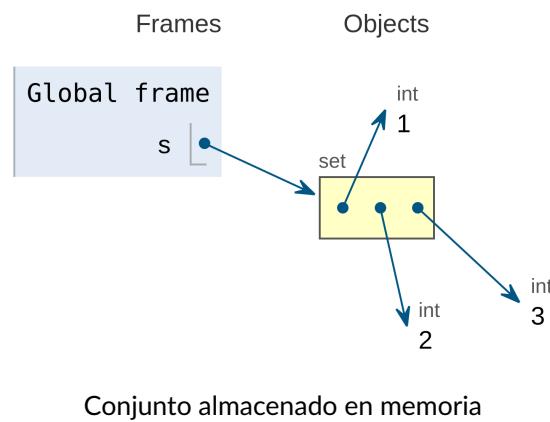
```
>>> s = {4, 3, 2, 2, 4}
>>> s
{2, 3, 4}
>>> t = set(s)
>>> t
{2, 3, 4}
>>> s == t
True
>>> s is t
False
```

En memoria, los conjuntos se almacenan mediante una estructura de datos donde sus elementos no se identifican mediante ningún índice o clave especial.

Por ejemplo, el siguiente conjunto:

```
d = {1, 2, 3}
```

se almacenaría de la siguiente forma según lo representa la herramienta Pythontutor:



1.2. Conjuntos por comprensión

También se pueden crear **conjuntos por comprensión** usando la misma sintaxis de las **expresiones generadoras** y las **listas por comprensión**, pero esta vez encerrando la expresión entre llaves.

Su sintaxis es:

```
<conj_comp> ::= {<expresión> <for> <identificador> <in> <secuencia> [<if> <condición>]]+ }
```

Por ejemplo:

```
>>> {x ** 2 for x in [1, 2, 3]}
{1, 4, 9}
```

El resultado es directamente un valor de tipo `set`, no un iterador.

Los conjuntos por comprensión, al igual que las expresiones generadoras y las listas por comprensión, **determinan su propio ámbito**.

Ese ámbito abarca todo el conjunto por comprensión, de principio a fin.

Al recorrer el iterable, las variables van almacenando en cada iteración del bucle el valor del elemento que en ese momento se está visitando.

Debido a ello, podemos afirmar que las variables que aparecen en cada cláusula `for` del conjunto por comprensión son **identificadores cuantificados**, ya que toman sus valores automáticamente y éstos están restringidos a los valores que devuelva el iterable.

Además, estos identificadores cuantificados son locales al conjunto por comprensión, y sólo existen dentro de él.

Debido a lo anterior, esos identificadores cumplen estas dos propiedades:

1. Se pueden renombrar (siempre de forma consistente) sin que el conjunto por comprensión cambie su significado.

Por ejemplo, los dos conjuntos por comprensión siguientes son equivalentes, puesto que producen el mismo resultado:

```
{x for x in (1, 2, 3)}
```

```
{y for y in (1, 2, 3)}
```

2. No se pueden usar fuera del conjunto por comprensión, ya que estarían fuera de su ámbito y no serían visibles.

Por ejemplo, lo siguiente daría un error de nombre:

```
>>> e = {x for x in (1, 2, 3)}
>>> x      # Intento acceder a la 'x' del conjunto por comprensión
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'x' is not defined
```

1.3. Operaciones

s y o son conjuntos, y x es un valor cualquiera:

Operación	Resultado
<code>len(s)</code>	Número de elementos de <u>s</u> (su cardinalidad)
<code>x in s</code>	<code>True</code> si <u>x</u> pertenece a <u>s</u>
<code>x not in s</code>	<code>True</code> si <u>x</u> no pertenece a <u>s</u>
<code>s.isdisjoint(o)</code>	<code>True</code> si <u>s</u> no tiene ningún elemento en común con <u>o</u>
<code>s.issubset(o)</code>	<code>True</code> si <u>s</u> es un subconjunto de <u>o</u>
<code>s < o</code>	<code>True</code> si <u>s</u> es un subconjunto propio de <u>o</u>
<code>s.issuperset(o)</code>	<code>True</code> si <u>s</u> es un superconjunto de <u>o</u>
<code>s > o</code>	<code>True</code> si <u>s</u> es un superconjunto propio de <u>o</u>

Operación	Resultado
<code>s.union(o)</code>	Unión de <u>s</u> y <u>o</u> ($s \cup o$)
<code>s o</code>	

Operación	Resultado
<code>s.intersection(o)</code> <code>s & o</code>	Intersección de <u>s</u> y <u>o</u> ($s \cap o$)
<code>s.difference(o)</code> <code>s - o</code>	Diferencia de <u>s</u> y <u>o</u> ($s \setminus o$)
<code>s.symmetric_difference(o)</code> <code>s ^ o</code>	Diferencia simétrica de <u>s</u> y <u>o</u> ($s \Delta o$)
<code>s.copy()</code>	Devuelve una copia superficial de <u>s</u>

Tanto `set` como `frozenset` admiten **comparaciones entre conjuntos**.

Suponiendo que `a` y `b` son conjuntos:

- `a == b` si y sólo si cada elemento de `a` pertenece también a `b`, y viceversa; es decir, si cada uno es un subconjunto del otro.
- `a <= b` si y sólo si `a` es un *subconjunto* de `b` (es decir, si cada elemento de `a` está también en `b`).
- `a < b` si y sólo si `a` es un *subconjunto propio* de `b` (es decir, si `a` es un subconjunto de `b`, pero no es igual a `b`).
- `a >= b` si y sólo si `a` es un *superconjunto* de `b` (es decir, si cada elemento de `b` está también en `a`).
- `a > b` si y sólo si `a` es un *superconjunto propio* de `b` (es decir, si `a` es un superconjunto de `b`, pero no es igual a `b`).

1.4. Operaciones sobre conjuntos mutables

Estas tablas sólo se aplica a conjuntos mutables (o sea, al tipo `set` y no al `frozenset`):

Operación	Resultado
<code>s.update(o)</code> <code>s = o</code>	Actualiza <u>s</u> añadiendo los elementos de <u>o</u>
<code>s.intersection_update(o)</code> <code>s &= o</code>	Actualiza <u>s</u> manteniendo sólo los elementos que están en <u>s</u> y <u>o</u>
<code>s.difference_update(o)</code> <code>s -= o</code>	Actualiza <u>s</u> eliminando los elementos que están en <u>o</u>
<code>s.symmetric_difference_update(o)</code> <code>s ^= o</code>	Actualiza <u>s</u> manteniendo sólo los elementos que están en <u>s</u> y <u>o</u> pero no en ambos

Operación	Resultado
<code>s.add(x)</code>	Añade <code>x</code> a <code>s</code>
<code>s.remove(x)</code>	Elimina <code>x</code> de <code>s</code> (produce <code>KeyError</code> si <code>x</code> no está en <code>s</code>)
<code>s.discard(x)</code>	Elimina <code>x</code> de <code>s</code> si está en <code>s</code>
<code>s.pop()</code>	Elimina y devuelve un valor cualquiera de <code>s</code> (produce <code>KeyError</code> si <code>s</code> está vacío)
<code>s.clear()</code>	Elimina todos los elementos de <code>s</code>

1.5. Recorrido de conjuntos

Como cualquier otro dato iterable, los conjuntos se pueden recorrer usando **iteradores**.

El **orden** en el que se recorren los elementos del conjunto **no está determinado de antemano**, es decir, que el iterador puede entregar los elementos del conjunto **en cualquier orden**:

Con un iterador:

```
>>> s = {3, 1, 2}
>>> it = iter(s)
>>> next(it)
1
>>> next(it)
2
>>> next(it)
3
```

Con un bucle **for**:

```
>>> s = {3, 1, 2}
>>> for e in s:
...     print(e)
...
1
2
3
```

Aunque, a la vista de este ejemplo, pudiera parecer que el conjunto siempre se va a recorrer como si estuviese ordenado, **no hay que confiar nunca** en que eso se vaya a cumplir siempre.

2. Diccionarios (`dict`)

2.1. Definición

Un **diccionario** (valor de tipo `dict`) es una colección que almacena *correspondencias* (o *asociaciones*) entre un conjunto de objetos llamados **claves** y un conjunto de objetos llamados **valores**.

Por tanto, **los elementos de un diccionario son parejas formadas por una clave y un valor**, de forma que el diccionario lo que hace es almacenar las claves y el valor que le corresponde a cada clave.

Además, los elementos de un diccionario son datos mutables y, por tanto, los diccionarios también son **mutables**.

En consecuencia, los diccionarios **NO** son *hashables*.

Los diccionarios se pueden crear:

- Con una pareja de llaves:

```
{}
```

que representan el **diccionario vacío**.

- Encerrando entre llaves una lista de parejas `<clave>:<valor>` separadas por comas:

```
{'juan': 4098, 'pepe': 4127}
```

Esa es precisamente la **expresión canónica** del diccionario y, por tanto, la que se usa cuando se visualiza desde el intérprete o se imprime con `print`.

- Usando la función `dict`.

Por ejemplo:

```
>>> v1 = {}                                # diccionario vacío
>>> v2 = dict()                            # también diccionario vacío
>>> v1 == v2                               # ¿son iguales?
True                                         # sí, son iguales
>>> a = {'uno': 1, 'dos': 2, 'tres': 3}    # literal de tipo dict
>>> b = dict(uno=1, dos=2, tres=3)         # paso de argumentos por palabra clave
>>> c = dict([('dos', 2), ('uno', 1), ('tres', 3)])  # lista de tuplas
>>> d = dict(((('dos', 2), ('uno', 1), ('tres', 3)))) # tupla de tuplas
>>> e = dict({('dos', 2), ('uno', 1), ('tres', 3)})   # conjunto de tuplas
>>> f = dict(zip(['uno', 'dos', 'tres'], [1, 2, 3])) # iterable que devuelve tuplas
>>> g = dict({'tres': 3, 'uno': 1, 'dos': 2})        # diccionario: crea una copia
```

Todos son iguales:

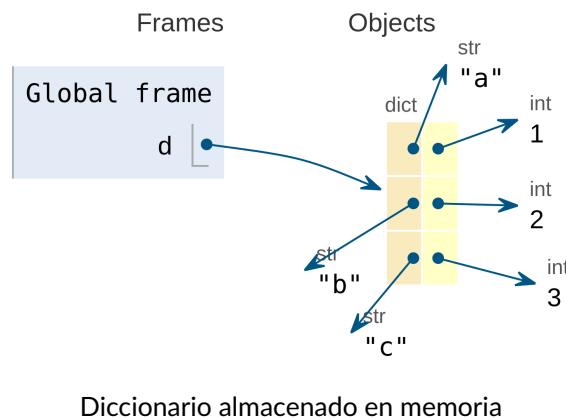
```
>>> a == b and b == c and c == d and d == e and e == f and f == g
True
```

En memoria, los diccionarios se almacenan como **tablas** de dos columnas, la clave y el valor.

Por ejemplo, el siguiente diccionario:

```
d = {'a': 1, 'b': 2, 'c': 3}
```

se almacenaría de la siguiente forma según lo representa la herramienta Pythontutor:



Diccionario almacenado en memoria

El tipo `dict[k, v]` representa el tipo de los diccionarios cuyas claves son todos de tipo `k` y cuyos valores son todos de tipo `v`.

Por ejemplo, el tipo `dict[str, int]` representa el tipo de los diccionarios cuyas claves son todas cadenas y cuyos valores son todos números enteros.

Las **claves** de un diccionario deben cumplir dos **restricciones**:

1. Deben ser **únicas** en ese diccionario.
2. Deben ser **hashables**.

Claves únicas

En un diccionario dado, **cada clave sólo puede asociarse con un único valor**.

Por tanto, **en un diccionario no puede haber claves repetidas**, es decir, que no puede haber dos elementos distintos con la misma clave.

Esto es así porque los elementos de un diccionario se identifican mediante su clave.

Así que, para acceder a un elemento dentro de un diccionario, debemos indicar la clave del elemento.

Los tipos numéricos que se usen como claves obedecen las reglas normales de comparación numérica.

Por tanto, si dos números son considerados iguales (como `1` y `1.0`) entonces se consideran la misma clave dentro del diccionario.

Si se intenta crear un diccionario con claves repetidas, sólo se almacenará uno de los elementos que tengan la misma clave (los demás se ignoran):

```
>>> a = {'perro': 'dog', 'gato': 'cat', 'perro': 'doggy'}
>>> a
{'perro': 'doggy', 'gato': 'cat'}
```

Como se ve, la clave '`perro`' está repetida y, por tanto, sólo se almacena uno de los dos elementos con clave repetida, que siempre es el último que se va a insertar en el diccionario.

En este caso, se almacena el elemento 'perro': 'doggy' y se ignora el 'perro': 'dog'.

Claves hashables

Por otra parte, las **claves** de un diccionario deben ser datos **hashables**.

Por tanto, no se pueden usar como clave una lista, un conjunto `set`, otro diccionario o cualquier otro dato mutable.

Si se intenta crear un diccionario con una clave no *hashable*, se produce un error `TypeError`:

```
>>> {[1, 2]: 'a', [3, 4]: 'b'}      # Las listas no son hashables
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: unhashable type: 'list'
>>> {{1, 2}: 'a', {3, 4}: 'b'}      # Los conjuntos set tampoco
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: unhashable type: 'set'
```

En cambio, sí se puede usar un `frozenset`, al ser *hashable*:

```
>>> {frozenset({1, 2}): 'a', frozenset({3, 4}): 'b'}
{frozenset({1, 2}): 'a', frozenset({3, 4}): 'b'}
```

Desde la versión 3.7 de Python, los elementos dentro de un diccionario se almacenan en **el orden en el que se van insertando dentro del diccionario**, aunque ese orden sólo tiene importancia en determinadas situaciones concretas.

Dos diccionarios se consideran **iguales** si ambos contienen los mismos elementos, es decir, si tienen las mismas parejas `<clave>:<valor>`, sin importar el orden en el que aparezcan los elementos en el diccionario:

```
>>> {'a': 1, 'b': 2} == {'b': 2, 'a': 1}
True
```

Para **acceder a un elemento** del diccionario se usa una sintaxis idéntica a la de la **indexación**, salvo que, en este caso, en lugar de usar el índice o posición del elemento, se usa la clave:

```
>>> a = {'perro': 'dog', 'gato': 'cat'}
>>> a['perro']
'dog'
```

Si se intenta acceder a un elemento usando una clave que no existe, se lanza una excepción de tipo `KeyError`:

```
>>> a['caballo']
Traceback (most recent call last):
File "<stdin>", line 1, in <module>
KeyError: 'caballo'
```

2.2. Diccionarios por comprensión

También se pueden crear **diccionarios por comprensión** usando una sintaxis análoga a la de los **conjuntos por comprensión** (encerrando la expresión entre llaves), pero de forma que los elementos estén formados por parejas de clave y valor separados por `:`.

Su sintaxis es:

```
<dict_comp> ::= {<clave>:<valor> (<for> <identificador> <in> <secuencia> [<if> <condición>])+}
```

donde `<clave>` debe ser una expresión que devuelva valores *hashables*, y `<valor>` puede ser una expresión cualquiera.

Por ejemplo:

```
>>> {x: x ** 2 for x in [1, 2, 3]}
{1: 1, 2: 4, 3: 9}
```

devuelve el diccionario que asocia a cada número 1, 2 y 3 con su correspondiente cuadrado.

Los diccionarios por comprensión, al igual que los conjuntos por comprensión, las expresiones generadoras y las listas por comprensión, **determinan su propio ámbito**.

Ese ámbito abarca todo el diccionario por comprensión, de principio a fin.

Al recorrer el iterable, las variables van almacenando en cada iteración del bucle el valor del elemento que en ese momento se está visitando.

Debido a ello, podemos afirmar que las variables que aparecen en cada cláusula `for` del diccionario por comprensión son **identificadores cuantificados**, ya que toman sus valores automáticamente y éstos están restringidos a los valores que devuelva el iterable.

Además, estos identificadores cuantificados son locales al diccionario por comprensión, y sólo existen dentro de él.

Debido a lo anterior, esos identificadores cumplen estas dos propiedades:

1. Se pueden renombrar (siempre de forma consistente) sin que el diccionario por comprensión cambie su significado.

Por ejemplo, los dos diccionarios por comprensión siguientes son equivalentes, puesto que producen el mismo resultado:

```
{x: x ** 2 for x in (1, 2, 3)}
```

```
{y: y ** 2 for y in (1, 2, 3)}
```

2. No se pueden usar fuera del diccionario por comprensión, ya que estarían fuera de su ámbito y no serían visibles.

Por ejemplo, lo siguiente daría un error de nombre:

```
>>> e = {x: x ** 2 for x in (1, 2, 3)}
>>> x      # Intento acceder a la 'x' del diccionario por comprensión
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'x' is not defined
```

2.3. Operaciones

d y o son diccionarios, c es una clave válida y v es un valor cualquiera:

Operación	Resultado
<code>d[c]</code>	Devuelve el valor asociado a <u>c</u> en <u>d</u> (lanza KeyError si <u>c</u> no está en <u>d</u>)
<code>d[c] = v</code>	Asocia a la clave <u>c</u> el valor <u>v</u> en <u>d</u> (crea el elemento dentro de <u>d</u> si la clave <u>c</u> no estaba ya en <u>d</u>)
<code>del d[c]</code>	Borra de <u>d</u> el elemento cuya clave es <u>c</u> (lanza KeyError si <u>c</u> no está en <u>d</u>)
<code>len(d)</code>	Número de elementos de <u>d</u>
<code>c in d</code>	<code>True</code> si <u>d</u> contiene un elemento con clave <u>c</u>
<code>c not in d</code>	<code>True</code> si <u>d</u> no contiene un elemento con clave <u>c</u>
<code>d.clear()</code>	Elimina todos los elementos de <u>d</u>
<code>d.copy()</code>	Devuelve una copia superficial de <u>d</u>

Operación	Resultado
<code>d.get(c[, def])</code>	Si la clave <u>c</u> está en <u>d</u> , devuelve <code>d[c]</code> ; si no está, devuelve <u>def</u> , que por defecto es <code>None</code>
<code>d.pop(c[, def])</code>	Si la clave <u>c</u> está en <u>d</u> , devuelve <code>d[c]</code> y elimina de <u>d</u> el elemento con clave <u>c</u> ; si no está, devuelve <u>def</u> (si no se pasa <u>def</u> y la clave <u>c</u> no está en <u>d</u> , lanza un KeyError)
<code>d.popitem()</code>	Selecciona un elemento de <u>d</u> siguiendo un orden LIFO, lo elimina de <u>d</u> y lo devuelve en forma de tupla (<code>clave, valor</code>) (lanza un KeyError si <u>d</u> está vacío)
<code>d.setdefault(c[, def])</code>	Si la clave <u>c</u> está en <u>d</u> , devuelve <code>d[c]</code> ; si no está, inserta en <u>d</u> un elemento con clave <u>c</u> y valor <u>def</u> , y devuelve <u>def</u> (que por defecto es <code>None</code>)
<code>d.update(o)</code>	Actualiza <u>d</u> con las parejas (<code>clave, valor</code>) de <u>o</u> , sobreescribiendo las claves ya existentes en <u>d</u> , y devuelve <code>None</code>

2.4. Recorrido de diccionarios

Como cualquier otro dato iterable, los diccionarios se pueden recorrer usando iteradores.

El orden en el que se recorren los elementos del diccionario es el orden en el que están almacenados los elementos dentro del diccionario que, como ya sabemos, desde la versión 3.7 de Python coincide con el orden en el que se han ido insertando los elementos en el diccionario.

Los iteradores creados sobre un diccionario, en realidad, recorren sus **claves**:

Con un iterador:

```
>>> d = {'a': 1, 'b': 2}
>>> it = iter(d)
>>> next(it)
'a'
>>> next(it)
'b'
```

Con un bucle **for**:

```
>>> d = {'a': 1, 'b': 2}
>>> for k in d:
...     print(k)
...
a
b
```

Si, además de acceder a las **claves**, necesitamos también acceder a los **valores** del diccionario mientras lo recorremos, podemos:

- Acceder al valor a partir de la clave usando **indexación**:

```
>>> for k in d:
...     print(k, d[k])
...
a 1
b 2
```

- Usar el método **items** sobre el diccionario (el cual devuelve un objeto que, al iterar sobre él, genera una secuencia de tuplas (**clave**, **valor**)), y combinarlo con el **desempaquetado de tuplas**:

```
>>> d.items()
dict_items([('a', 1), ('b', 2)])
>>> for k, v in d.items():
...     print(k, v)
...
a 1
b 2
```

Otros métodos útiles para recorrer un diccionario son **keys** y **values**.

keys devuelve un iterador que va entregando las **claves** del diccionario sobre el que se invoca:

```
>>> d.keys()
dict_keys(['a', 'b'])
>>> for k in d.keys():
...     print(k)
...
a
b
```

`values` devuelve un iterador que va entregando los **valores** del diccionario sobre el que se invoca:

```
>>> d.values()
dict_values([1, 2])
>>> for v in d.values():
...     print(v)
...
1
2
```

En la práctica, no resulta muy útil usar `keys`, ya que se puede hacer lo mismo recorriendo directamente el propio diccionario, como ya sabemos:

```
>>> for k in d:
...     print(k)
...
a
b
```

3. Documentos XML

3.1. Definición

Un **lenguaje de intercambio de datos** es un formato para el intercambio de datos entre aplicaciones informáticas de manera que no necesitan estar codificados en el mismo lenguaje de programación o instalados en un mismo sistema operativo.

Son formatos estandarizados que permiten la comunicación y transferencia de información entre diferentes sistemas, aplicaciones o plataformas, independientemente del lenguaje de programación en el que hayan sido desarrollados.

Los más utilizados en la actualidad son:

- XML.
- JSON.
- YAML.
- CSV.

Los **documentos XML** se pueden considerar **datos estructurados en forma de árbol** (es decir, con una estructura **jerárquica** y, por tanto, **no secuencial**).

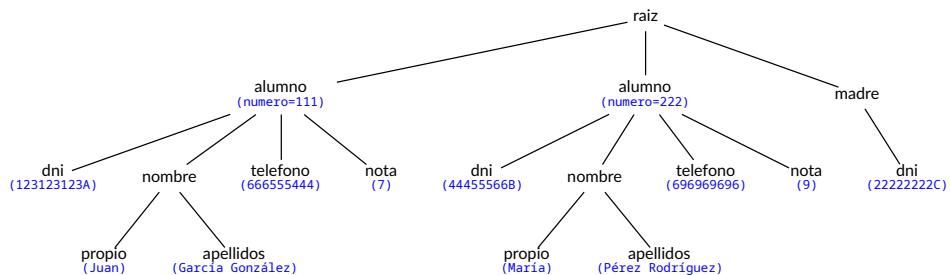
Por ejemplo, supongamos el siguiente documento XML:

```
<?xml version="1.0"?>
<raiz>
    <alumno numero="111">
        <dni>12312312A</dni>
        <nombre>
            <propio>Juan</propio>
            <apellidos>García González</apellidos>
        </nombre>
        <telefono>666555444</telefono>
        <nota>7</nota>
    </alumno>
    <alumno numero="222">
        <dni>44455566B</dni>
        <nombre>
            <propio>María</propio>
            <apellidos>Pérez Rodríguez</apellidos>
        </nombre>
        <telefono>696969696</telefono>
        <nota>9</nota>
    </alumno>
    <madre>
        <dni>22222222C</dni>
    </madre>
</raiz>
```

Podemos encontrarnos lo siguiente:

- Lo que hay entre ángulos (como `<raiz>`) es una *etiqueta*.
- Lo que hay entre dos etiquetas (como el 7 en `<nota>7</nota>`) es el *texto* de la etiqueta.
- Lo que hay dentro de la etiqueta (como `numero="111"`) es un *atributo* de la etiqueta.
 - `numero="111"` es un atributo de la primera etiqueta `<alumno>`.
 - `numero` es el *nombre* del atributo.
 - 111 es el *valor* del atributo `numero`.
- Puede haber etiquetas con uno o varios atributos y etiquetas sin atributos.

Ese documento representaría la siguiente estructura jerárquica:



Se observa que:

- **Cada nodo representa una etiqueta** del documento XML.
- Si una etiqueta contiene a otra, su correspondiente nodo en el árbol tendrá un hijo que representa a la etiqueta que contiene.

- Los hijos de un nodo están ordenados por la posición que ocupan dentro de su etiqueta padre.

3.2. Acceso

El módulo `xml.etree.ElementTree` (documentado en <https://docs.python.org/3/library/xml.etree.elementtree.html>) implementa una interfaz sencilla y eficiente para interpretar y crear datos XML.

Para importar los datos de un archivo XML, podemos hacer:

```
import xml.etree.ElementTree as ET
arbol = ET.parse('archivo.xml')
raiz = arbol.getroot()
```

Si los datos XML se encuentran ya en una cadena, se puede hacer directamente:

```
raiz = ET.fromstring(datos_en_una_cadena)
```

Los nodos del árbol se representan internamente mediante objetos de tipo `Element`, los cuales disponen de ciertos atributos y responden a ciertos métodos.

¡Cuidado! Aquí, cuando hablamos de *atributos*, nos referimos a información que contiene el objeto (una cualidad del objeto según el *paradigma orientado a objetos*) y a la cual se puede acceder usando el operador punto (`.`), no a los atributos que pueda tener una etiqueta según consten en el documento XML.

Los objetos de tipo `Element` disponen de los siguientes atributos:

- `tag`: una cadena que representa a la etiqueta del nodo (por ejemplo: si la etiqueta es `<alumno>`, entonces `tag` contendrá `'alumno'`).
- `attrib`: un diccionario que representa a los atributos de esa etiqueta en el documento XML.
- `text`: una cadena que representa el contenido del nodo, es decir, el texto que hay entre `<etiqueta>` y `</etiqueta>`.

Por ejemplo, si tenemos la siguiente etiqueta en el documento XML:

```
<telefono tipo="movil">666555444</telefono>
```

y la variable `nodo` contiene el nodo (es decir, el objeto `Element`) que representa a dicha etiqueta en el árbol, entonces:

- `nodo.tag` valdrá `'telefono'`.
- `nodo.attrib` valdrá `{'tipo': 'movil'}`.
- `nodo.text` valdrá `'666555444'`.

En nuestro caso, `raiz` es un objeto de tipo `Element` que, además, representa al nodo raíz del árbol XML.

Por tanto, tendríamos lo siguiente:

```
>>> raiz.tag
'raiz'
>>> raiz.attrib
{}
>>> raiz.text
'\n' # ¿Por qué?
```

Los objetos `Element` son **iterables**. Por ejemplo, el nodo raíz tiene **nodos hijos** (nodos que «cuelgan» directamente del nodo raíz) sobre los cuales se puede iterar desde el objeto `raiz`:

```
>>> for hijo in raiz:
...     print(hijo.tag, hijo.attrib)
...
alumno {'numero': '111'}
alumno {'numero': '222'}
madre {}
```

Los hijos de un nodo están ordenados entre sí por la posición relativa que ocupan sus respectivas etiquetas en el documento XML, así que podemos decir «el primer hijo del nodo», «el segundo hijo del nodo», etc.

Por ejemplo, supongamos que en un documento XML:

- Hay una etiqueta `<R>`.
- Hay dos etiquetas llamadas `<A>` y ``, y son las únicas etiquetas que aparecen directamente dentro de la etiqueta `<R>`.
- La etiqueta `<A>` aparece antes que la `` en el documento XML.

En ese caso:

- El nodo de `A` será el primer hijo de `R` en el árbol (ocupa la *posición 0*).
- El nodo de `B` será el segundo hijo de `R` en el árbol (ocupa la *posición 1*).

Esa *posición* representa el **índice** del nodo dentro de la secuencia de nodos hijos que tiene su nodo padre.

Podemos acceder a nodos concretos a través de su índice usando **indexación** desde su nodo padre, por lo que podemos afirmar que los objetos `Element` son **indexables**:

```
>>> raiz[0]      # el primer hijo directo de raiz
<Element 'alumno' at 0x7f929c29cf90>
>>> raiz[1]      # el segundo hijo directo de raiz
<Element 'alumno' at 0x7f16266d0310>
```

Además, los nodos están anidados, por lo que podemos hacer esto:

```
>>> raiz[0]      # el primer hijo directo de raiz
<Element 'alumno' at 0x7f929c29cf90>
>>> raiz[0][2]   # el tercer hijo directo del primer hijo directo de raiz
<Element 'telefono' at 0x7f929c29d180>
```

```
>>> raiz[0][2].text  
'666555444'
```

Con la función `len` podemos saber cuántos hijos tiene un nodo:

```
>>> len(raiz)  
3
```

Un objeto `Element` representa un nodo de un árbol XML, pero sus hijos se exponen como una secuencia ordenada.

Visto así, podemos decir que *se comportan parcialmente como secuencias*, pero no son secuencias completas en el sentido en que pueden serlo `list` o `tuple`.

Un objeto `Element` soporta las siguientes operaciones de secuencias:

- Indexación: `nodo[i]`
- Iteración: `iter(nodo)`, y de ahí: `for hijo in nodo`
- Longitud: `len(nodo)`
- Rodajas: `nodo[i:j:k]`
- Pertenencia: `hijo in nodo`

Pero no soporta otras, como la concatenación, la repetición, la función `sorted` o la comparación con `<`.

Los objetos de tipo `Element` disponen de métodos útiles para iterar recursivamente sobre todos los subárboles situados debajo de él (sus hijos, los hijos de sus hijos, y así sucesivamente).

Por ejemplo, el método `iter` devuelve un **iterador** que recorre todos los nodos del árbol desde el nodo actual (el nodo sobre el que se invoca al método) en un orden **primero en profundidad**.

Eso quiere decir que va visitando los nodos en el mismo orden en el que se encuentran escritos en el documento XML, incluyendo el propio nodo sobre el que se invoca.

Por ejemplo:

```
>>> for nodo in raiz.iter():  
...     print(nodo.tag)  
...  
raiz  
alumno  
dni  
nombre  
propio  
apellidos  
telefono  
nota  
alumno  
dni  
nombre  
propio  
apellidos  
telefono
```

```
nota  
madre  
dni
```

Si se le pasa una etiqueta como argumento, devolverá únicamente los nodos que tengan esa etiqueta:

```
>>> for dni in raiz.iter('dni'):  
...     print(dni.text)  
...  
12312312A  
44455566B  
22222222C
```

El método `findall` devuelve una lista con los nodos que tengan una cierta etiqueta y que sean hijos directos del nodo sobre el que se invoca.

Devuelve una lista vacía si no hay nodos que cumplan la condición.

El método `iterfind` funciona de forma similar pero devuelve un iterador en lugar de una lista.

El método `find` devuelve el primer hijo directo del nodo sobre el que se invoca, siempre que tenga una cierta etiqueta indicada como argumento.

Devuelve `None` si el nodo no tiene ningún hijo con esa etiqueta.

El método `get` devuelve el valor de algún atributo de la etiqueta asociada a ese nodo:

```
>>> for alumno in raiz.findall('alumno'):  
...     numero = alumno.get('numero')  
...     dni = alumno.find('dni').text  
...     print(numero, dni)  
...  
111 12312312A  
222 44455566B
```

Si la etiqueta no tiene el atributo indicado en el argumento de `get`, éste devuelve `None` o el valor que se haya indicado en el segundo argumento:

```
>>> alumno = raiz[0]  
>>> alumno.get('numero')  
111  
>>> alumno.get('altura')  
None  
>>> alumno.get('altura', 0)  
0  
>>> alumno.get('numero', 0)  
111
```

También disponemos de la función `dump` que devuelve la cadena correspondiente al nodo que se le pase como argumento:

```
>>> ET.dump(raiz[0][2])  
<telefono>666555444</telefono>
```

Para una especificación más sofisticada de los elementos a encontrar, se pueden usar las expresiones XPath con `find`, `findall` o `iterfind`:

Sintaxis	Significado
etiqueta	Selecciona todos los nodos hijo con la etiqueta etiqueta . Por ejemplo, <code>pepe</code> selecciona todos los nodos hijo llamados <code>pepe</code> , y <code>pepe/juan</code> selecciona todos los nietos llamados <code>juan</code> en todos los hijos llamados <code>pepe</code> .
*	Selecciona todos los nodos hijo inmediatos. Por ejemplo, <code>*/pepe</code> selecciona todos los nietos llamados <code>pepe</code> .
.	Selecciona el nodo actual. Se usa, sobre todo, al principio de la ruta para indicar que es una ruta relativa.
//	Selecciona todos los subnodos en cualquier nivel por debajo de un nodo. Por ejemplo, <code>./pepe</code> selecciona todos los nodos <code>pepe</code> que haya en todo el árbol.
..	Selecciona el nodo padre. Devuelve <code>None</code> si se intenta acceder a un ancestro del nodo de inicio (aquel sobre el que se ha llamado a <code>find</code> , <code>findall</code> o <code>iterfind</code>).

Continuación de las expresiones XPath:

Sintaxis	Significado
<code>[@atrib]</code>	Selecciona todos los nodos que tienen el atributo atrib .
<code>[@atrib='valor']</code>	Selecciona todos los nodos que tienen el valor valor en el atributo atrib . El valor no puede contener apóstrofes.
<code>[@atrib != 'valor']</code>	Selecciona todos los nodos que tienen el valor valor en el atributo atrib . El valor no puede contener apóstrofes.
<code>[etiqueta]</code>	Selecciona todos los nodos que tienen un hijo inmediato llamado etiqueta .
<code>[posición]</code>	Selecciona todos los nodos situados en cierta posición . Ésta puede ser un entero (1 es la primera posición), la expresión <code>last()</code> (la última posición) o una posición relativa a la última posición (por ejemplo, <code>last() - 1</code>).

Ejemplos

```
# Los nodos de nivel más alto:
>>> raiz.findall(".")
[<Element 'raiz' at 0x7f929c29cf40>]

# Los nietos 'dni' de los hijos 'alumno' de los nodos de nivel más alto:
>>> raiz.findall("./alumno/dni")
[<Element 'dni' at 0x7f929c29d040>,
 <Element 'dni' at 0x7f929c29d270>]
```

```
# Lo de antes equivale a hacer (porque el nodo actual es el raíz):
>>> raiz.findall("alumno/dni")
[<Element 'dni' at 0x7f929c29d040>,
 <Element 'dni' at 0x7f929c29d270>]

# Los nodos con numero='111' que tienen un hijo 'dni':
>>> raiz.findall("./dni/..[@numero='111']")
[<Element 'alumno' at 0x7f929c29cf90>]

# Antes de // hay que poner algo que indique el nodo debajo del
# cual se va a buscar:
>>> raiz.findall("//dni/..[@numero='111']")
SyntaxError: cannot use absolute path on element
```

Ejemplos

```
# Todos los nodos 'dni' del árbol completo:
>>> raiz.findall('./dni')
[<Element 'dni' at 0x7f547a0e9950>,
 <Element 'dni' at 0x7f547a0e9b80>,
 <Element 'dni' at 0x7f547a0e9e00>]

# Sólo los DNIs que estén por debajo de un nodo 'madre'
# en cualquier nivel:
>>> raiz.findall('madre//dni')
[<Element 'dni' at 0x7f547a0e9e00>]

# Los nodos 'dni' que son hijos de los nodos con numero='111':
>>> raiz.findall("./*[@numero='111']/dni")
[<Element 'dni' at 0x7f929c29d040>]

# Los nodos 'alumno' que son hijos segundos de sus padres:
>>> raiz.findall("./alumno[2]")
[<Element 'alumno' at 0x7f929c29d220>]

# Los nodos 'alumno' hijos directos del actual que tienen un hijo 'nota':
>>> raiz.findall("./alumno[nota]")
[<Element 'alumno' at 0x7f929c29cf90>,
 <Element 'alumno' at 0x7f929c29d220>]

# Lo de antes equivale a hacer (porque el nodo actual es el raíz):
>>> raiz.findall("alumno[nota]")
[<Element 'alumno' at 0x7f929c29cf90>,
 <Element 'alumno' at 0x7f929c29d220>]
```

3.3. Modificación

`ElementTree` proporciona una forma sencilla de crear documentos XML y escribirlos en archivos.

Para ello, usamos el método `write`.

Una vez creado, un objeto `Element` puede manipularse directamente:

- Cambiando los atributos del objeto, como `text` o `attrib`.
- Cambiando los atributos de la etiqueta a la que representa el objeto, con el método `set`.
- Añadiendo nuevos hijos con los métodos `append` o `insert`.

- Eliminando hijos con el método `remove`.

Por ejemplo, supongamos que queremos sumarle 1 a la `nota` de cada alumno y añadir un atributo `modificado` a la etiqueta `nota`:

```
>>> for nota in raiz.iter('nota'):
...     nueva_nota = int(nota.text) + 1
...     nota.text = str(nueva_nota)
...     nota.set('modificado', 'si')
...
>>> arbol.write('salida.xml')
```

Nuestro XML tendría ahora el siguiente aspecto:

```
<?xml version="1.0"?>
<raiz>
    <alumno numero="111">
        <dni>12312312A</dni>
        <nombre>
            <propio>Juan</propio>
            <apellidos>García González</apellidos>
        </nombre>
        <telefono>666555444</telefono>
        <nota modificado="si">8</nota>
    </alumno>
    <alumno numero="222">
        <dni>44455566B</dni>
        <nombre>
            <propio>María</propio>
            <apellidos>Pérez Rodríguez</apellidos>
        </nombre>
        <telefono>696969696</telefono>
        <nota modificado="si">10</nota>
    </alumno>
    <madre>
        <dni>22222222C</dni>
    </madre>
</raiz>
```

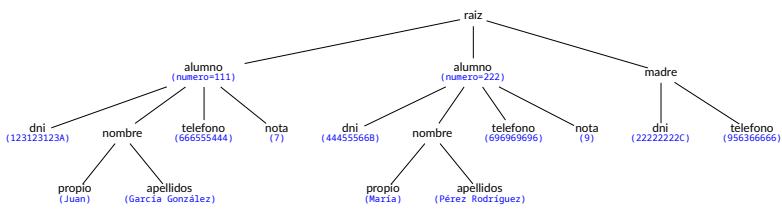
Podemos insertar nuevos nodos hijos de un determinado nodo con los métodos `append` o `insert`, como si el nodo fuese una lista.

Para ello, primero normalmente crearemos el nodo que vamos a insertar usando `Element(etiqueta)`.

Por ejemplo, añadimos el teléfono a la única madre que tenemos en el documento XML:

```
telefono = ET.Element('telefono')
telefono.text = '95636666'
madre = raiz.find('madre')
madre.append(telefono)
```

Tras estas operaciones, ahora tendríamos:



Podríamos haber usado `insert` en lugar de `append` para cambiar la posición donde situar el nodo hijo.

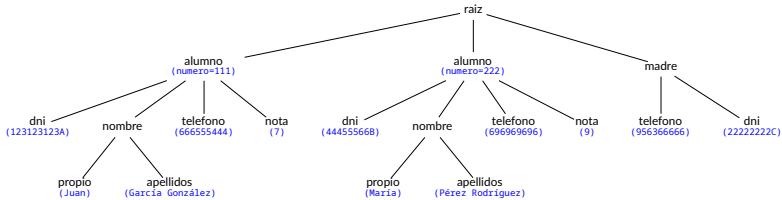
Por ejemplo, si queremos situar el teléfono antes que el DNI, podríamos hacer:

```

telefono = ET.Element('telefono')
telefono.text = '956366666'
madre = raiz.find('madre')
madre.insert(0, telefono)

```

Tras estas operaciones, ahora tendríamos:



Podemos eliminar elementos con el método `remove`. Por ejemplo, supongamos que queremos eliminar todos los alumnos con una nota inferior a 9:

```

>>> for alumno in raiz.findall('alumno'):
...     # se usa findall para que no afecte el borrado durante el recorrido
...     nota = int(alumno.find('nota').text)
...     if nota < 9:
...         raiz.remove(alumno)
...
>>> arbol.write('salida.xml')

```

Tener en cuenta que la modificación concurrente mientras se hace una iteración puede dar problemas, lo mismo que ocurre cuando se modifican listas o diccionarios mientras se itera sobre ellos.

Por ello, el ejemplo primero recoge todos los elementos con `findall` y sólo entonces itera sobre la lista que devuelve.

Si usáramos `iter` en lugar de `findall` se podrían dar problemas debido a que `iter` va devolviendo perezosamente los nodos (es un iterador) y el conjunto de nodos que devuelve podría verse afectado por los borrados.

Nuestro XML tendría ahora el siguiente aspecto:

```

<?xml version="1.0"?>
<raiz>
    <alumno numero="222">

```

```

<dni>44455566B</dni>
<nombre>
    <propio>María</propio>
    <apellidos>Pérez Rodríguez</apellidos>
</nombre>
<telefono>696969696</telefono>
<nota modificada="si">10</nota>
</alumno>
<madre>
    <dni>22222222C</dni>
</madre>
</raiz>

```

Si lo que queremos es **mover** un nodo (es decir, cambiar un nodo de sitio), podemos combinar los efectos de `append` e `insert` con `remove`.

Por ejemplo, si queremos mover la etiqueta `<madre>` dentro de la etiqueta `<alumno>`, podríamos hacer:

```

madre = raiz.find('madre')
raiz.remove(madre)
alumno = raiz.find('alumno')
alumno.append(madre)

```

Nuestro XML tendría ahora el siguiente aspecto:

```

<?xml version="1.0"?>
<raiz>
    <alumno numero="222">
        <dni>44455566B</dni>
        <nombre>
            <propio>María</propio>
            <apellidos>Pérez Rodríguez</apellidos>
        </nombre>
        <telefono>696969696</telefono>
        <nota modificada="si">10</nota>
        <madre>
            <dni>22222222C</dni>
        </madre>
    </alumno>
</raiz>

```

La función `SubElement` también proporciona una forma muy conveniente de crear sub-elementos de un elemento dado:

```

>>> a = ET.Element('a')
>>> b = ET.SubElement(a, 'b')
>>> c = ET.SubElement(a, 'c')
>>> d = ET.SubElement(c, 'd')
>>> ET.dump(a)
<a><b /><c><d /></c></a>

```

Bibliografía

Python Software Foundation. n.d. *Sitio Web de Documentación de Python*. <https://docs.python.org/3>.